

회귀와 분류 (regression and classification)

회귀(regression)와 분류(classification)

• 회귀 모델

- 연속적인 값을 예측
 - 캘리포니아의 주택 가격이 얼마인가요?
 - 사용자가 이 광고를 클릭할 확률이 얼마인가요?


• 분류 모델

- 불연속적인 값을 예측
 - 주어진 이메일 메시지가 스팸인가요, 스팸이 아닌가요?
 - 이 이미지가 강아지, 고양이 또는 햄스터의 이미지인가요?

Classification VS Regression



classify input into categorical output



how tall is he if his weight is 80kg?

회귀의 어원

- 회귀 분석(regression analysis)

- 관찰된 연속형 변수들에 대해 두 변수 사이의 모형을 구한 뒤 적합도를 측정해 내는 분석 방법
- 회귀분석은 시간에 따라 변화하는 데이터나 어떤 영향, 가설적 실험, 인과 관계의 모델링 등의 통계적 예측에 이용

- 회귀(영어: regress 리그레스[*])의 원래 의미

- 옛날 상태로 돌아가는 것을 의미
- 영국의 유전학자 프랜시스 골턴은 "평균으로의 회귀(regression to the mean)"
 - 부모의 키와 아이들의 키 사이의 연관 관계를 연구하면서 부모와 자녀의 키 사이에는 선형적인 관계가 있고 키가 커지거나 작아지는 것보다는 전체 키 평균으로 돌아가려는 경향이 있다는 가설을 세웠으며 이를 분석하는 방법을 "회귀분석"이라고 함
 - 이러한 경험적 연구 이후, 칼 피어슨은 아버지와 아들의 키를 조사한 결과를 바탕으로 함수 관계를 도출하여 회귀분석 이론을 수학적으로 정립

선형 회귀 (linear regression)

선형 회귀와 로지스틱 회귀

• 단순 선형 회귀 분석(Simple Linear Regression Analysis)

- 입력: 특징이 하나
- 출력: 하나의 값
 - 키로 몸무게 추정

$$H(x) = Wx + b$$

• 다중 선형 회귀 분석(Multiple Linear Regression Analysis)

- 입력: 특징이 여러 개, 출력: 하나의 값
 - 역세권, 아파트 평수, 주소로 아파트값을 추정

$$y = W_1x_1 + W_2x_2 + \dots W_nx_n + b$$

• 로지스틱 회귀(Logistic Regression)


- 이진 분류(Binary Classification)
- 입력: 하나 또는 여러 개, 출력: 0 아니면 1
 - 타이타닉의 승객 정보로 죽음을 추정

score(x)	result(y)
45	불합격
50	불합격
55	불합격
60	합격
65	합격
70	합격

인공지능이란? **W**와 **b** 구하기

- 다음 식에서 가중치 **W**와 편향 **b**를 구하기
 - **W**와 **b**를 매개변수 함

$$H(x) = Wx + b$$



매개변수
parameters

$$\theta = (w, b)$$

주요 용어 정리

- **가설(Hypothesis)**
 - 가중치(weight)와 편향(bias)
 - 기울기와 절편
- **손실 함수(Loss Function)**
 - MSE(Mean Square Error 평균제곱오차)
 - Categorical crossentropy
 - Sparse Categorical crossentropy
- **경사 하강법(Gradient Descent)**
 - 내리막 경사 따라 가기
- **학습률(learning rate)**
 - 대표적인 하이퍼패러미터

선형 회귀

- Linear regression

- 데이터의 경향성을 가장 잘 설명하는 하나의 직선을 예측하는 방법

- $Y = aX + b$

- 기울기 a 와 절편인 b 를 구하는 것

- 사례


- 국어와 수학 성적
 - 키와 몸무게
 - 치킨과 맥주의 판매량
 - 기저귀와 맥주의 판매량

- 딥러닝 분야에서

- 선형 회귀


- $Y = wX + b$

- 가중치 w 와 편향인 b 를 구하는 것



선형 회귀 문제 사례

- 공부 시간이 x 라면, 점수는 y



hours(x)	score(y)
2	25
3	50
4	42
5	61


- 알려준 데이터로부터 x 와 y 의 관계를 유추
 - 학생이 6시간을 공부하였을 때의 성적
 - 그리고 7시간, 8시간을 공부하였을 때의 성적을 예측

가설

- 머신 러닝: y 와 x 간의 관계를 유추한 식을 가설(Hypothesis)
- $H(x)$ 에서 H 는 Hypothesis를 의미

$$H(x) = Wx + b$$

W : 기울기, 가중치
 b : 절편, 편향




- 선형 회귀에서 해야할 일은 결국 적절한 W 와 b 를 찾아내는 일
- 딥러닝 알고리즘이 하는 것이 바로 적절한 W 와 b 를 찾아내는 일


손실 함수(Loss function)

- 머신 러닝은 W와 b를 찾기 위해서
 - 손실 함수를 정의
 - 실제 값과 가설로부터 얻은 예측 값의 오차를 계산하는 식
 - 손실 함수 값을 최소화하는 최적의 W와 b를 찾아내려고 노력
- 손실 함수(Loss function)
 - 목적 함수(Objective function), 비용 함수(Cost function)라고도 부름
 - 실제 값과 예측 값에 대한 오차에 대한 식
 - 예측 값의 오차를 줄이는 일에 최적화 된 식
 - 평균 제곱 오차(Mean Squared Error, MSE) 등을 사용

$$\frac{1}{n} \sum_i^n [y_i - H(x_i)]^2$$



실제 값




예측 값

손실 함수: MSE

- W 와 b의 값을 찾아내기 위해 오차의 크기를 측정할 방법이 필요
 - W: 13 b: 1로 예측한다면 $y=13x+1$ 직선이 예측한 함수로 예측 값을 추정

hours(x)	2	3	4	5
실제값	25	50	42	61
예측값	27	40	53	66
오차	-2	10	-7	-5


$$\frac{1}{n} \sum_i^n [y_i - H(x_i)]^2$$



손실 함수 MSE 이해

- MSE

- 오차는 실제 데이터(빨간 점)와 예측 선(파란 선)의 차이의 제곱의 합



손실 함수를 **W**와 **b**의 함수로

- 평균 제곱 오차를 W와 b에 의한 비용 함수(Cost function)로 재정의

$$cost(W, b) = \frac{1}{n} \sum_i^n [y_i - H(x_i)]^2$$

- 모든 점들과의 오차가 클수록 평균 제곱 오차는 커지며,
 - 오차가 작아질수록 평균 제곱 오차는 작아짐

- 평균 제곱 오차

- $cost(W, b)$ 를 최소가 되게 만드는 W와 b를 구하면
 - 결과적으로 y와 x의 관계를 가장 잘 나타내는 직선을 그릴 수 있게 됨

$$W, b \rightarrow \text{minimize } cost(W, b)$$


옵티마이저(Optimizer): 최적화 과정

머신 러닝에서 학습(training)

- 최적화 알고리즘(Optimizer algorithms)
- 적절한 W 와 b 를 찾아내는 과정


Gradient Descent(경사 하강법)

- 비용 함수(Cost Function)의 값을 최소로 하는 W 와 b 를 찾는 방법
- 경사 따라 내려 오기



손실과 가중치


- 손실과 가중치 w_i 을 대응한 그림
 - 항상 볼록 함수 모양을 함
 - 도표가 다음과 같이 항상 그릇 모양으로 나타남
- 볼록 문제에는 기울기가 정확하게 0인 지점인 최소값이 하나만 존재
 - 이 최소값에서 손실 함수가 수렴
 - 결국 기울기를 구해야 함



경사하강법


경사하강법의 첫 번째 단계

- 시작 값(시작점)을 선택
 - 시작점은 별로 중요하지 않음
 - 따라서 많은 알고리즘에서는 0으로 설정하거나 임의의 값을 선택
- 시작점에서 손실 곡선의 기울기를 계산
 - 단일 가중치에 대한 손실의 기울기는 미분 값과 같음



가중치의 조정

- 기울기가 0인 지점을 찾기 위해
 - 기울기의 반대 방향으로 이동
 - 현재의 기울기가 음수이면
 - 다음 가중치 값은 현재의 값보다 크게 조정



학습률

• 다음 가중치 값 결정 방법

- 기울기에 학습률(또는 보폭이라 불리는 스칼라)을 곱하여 다음 지점을 결정

- 예를 들어 기울기가 -2.5이고 학습률이 0.01이면

- $w = w - (-2.5 \times 0.01) = w + 0.025$



- 경사하강법 알고리즘은 이전 지점으로부터 0.025 떨어진 지점을 다음 지점으로 결정

• 학습률의 값

- 너무 작게 설정하면 학습 시간이 매우 오래 걸림


- 반대로 학습률을 너무 크게 설정하면

- 다음 지점이 곡선의 최저점을 무질서하게 이탈할 우려가 있음



적절한 학습률 설정

- 손실 함수의 기울기가 작다면 더 큰 학습률을 시도해 볼 수 있음
 - 작은 기울기를 보완하고 더 큰 보폭을 만들어 냄



초매개변수와 학습률

- 초매개변수(hyperparameter)
 - 딥러닝에서 우리가 설정하는 값
 - 모델 학습을 연속적으로 실행하는 중에 개발자 본인에 의해 조작되는 '손잡이'
 - 예를 들어 학습률은 초매개변수 중 하나
 - 매개변수와 대비되는 개념

학습률 실험

• 다양한 학습률로 실험

- 이러한 학습률이 손실 곡선의 최저점에 도달하는 데 필요한 단계 수에 어떤 영향을 미치는지 확인
- <https://developers.google.com/machine-learning/crash-course/fitter/graph?hl=ko>
- 머신러닝 단기집중과정 메뉴
 - 손실 줄이기 | 학습률 최적화

• 학습률 α

- W 의 값을 변경할 때
 - 얼마나 크게 변경할지를 결정
- 얼마나 큰 폭으로 이동할 지를 결정
 - 학습률 α 의 값을 무작정 크게 하면
 - W 의 값이 발산하는 상황
 - 학습률 α 가 지나치게 낮은 값을 가지면
 - 학습 속도가 느려지므로 적당한 α 의 값을 찾아내는 것도 중요

• 0.001에서 0.1 정도 사용

학습률 최적화

의견 보내기


🕒 예상 시간: 15분

다양한 학습률로 실험하고, 이러한 학습률이 손실 곡선의 최저점에 도달하는 데 필요한 단계 수에 어떤 영향을 미치는지 확인합니다. 그래프 아래에서 실험해 보세요.

학습률 설정: 0.70

한 단계 실행: 2


그래프 재설정:



Python

cost가 가장 최소값을 가지게 하는 W 를 찾는 일

- $y = Wx$ 라는 가설 $H(x)$
 - 비용 함수의 값 $\text{cost}(W)$
 - 설명의 편의를 위해 편향 b 가 없이 단순히 가중치 W 만을 사용



비용 함수와 최적의 W 구하기

- 비용 함수(Cost function)

$$cost(W) = \frac{1}{n} \sum_i^n [y_i - H(x_i)]^2$$

- Cost를 최소화하는 W 를 구하기 위한 식

- 해당 식은 접선의 기울기가 0이 될 때까지 반복

$$W := W - \alpha \frac{\partial}{\partial W} cost(W)$$

학습률(learning rate)

W 함수의 기울기:
미분 값

- 현재 W 에서의 접선의 기울기와 α 와 곱한 값을 현재 W 에서 빼서 새로운 W 의 값으로 다음 손실을 계산
- 학습률(알파): 기울기가 최소인 다음 w 로 가기 위한 비율

계산 과정의 의미

• 현재 W에서 현재 W에서의 접선의 기울기를 빼는 행위의 의미


- 접선의 기울기가 음수일 때

$$W := W - \alpha(\text{음수}) = W + \alpha(\text{양수})$$

- 접선의 기울기가 양수일 때


$$W := W - \alpha(\text{양수})$$

$$W := W - \alpha \frac{\partial}{\partial W} \text{cost}(W)$$




경사 하강법 정리

- **경사 하강법(Gradient Descent)**
 - 내리막 경사 따라 가기
 - 접선의 기울기
 - 맨 아래의 볼록한 부분에서는 결국 접선의 기울기가 0
 - cost가 최소화 되는 지점은 접선의 기울기가 0이 되는 지점
 - 또한 미분값이 0이 되는 지점
 - 경사 하강법의 아이디어
 - 비용 함수(Cost function)를 미분하여 현재 W 에서의 접선의 기울기를 구하고
 - 접선의 기울기가 낮은 방향으로 W 의 값을 변경하고 다시 미분하고
 - 이 과정을 접선의 기울기가 0인 곳을 향해 W 의 값을 변경하는 작업을 반복하는 것



손실 함수를 최소로 하는 **W**와 **b** 구하는 과정



오차역전파

• 순전파와 역전파

- 순전파, 역전파, 가중치 수정, 순전파 ...를 계속 반복해 나가면서 오차 값이 적어지도록

• 1986년 제프리 힌튼이 적용

- 엄청난 처리 속도의 증가

